Focus Veille — OpenAI & le Pentagone : l'IA au cœur de la défense américaine

Contexte

Fin février 2026, Sam Altman a officialisé l'entrée d'OpenAI au cœur de l'appareil militaire américain Génération NT en signant un accord avec le Département de la Défense américain (rebaptisé "Département de la Guerre" par l'administration Trump). Ce contrat de 200 millions de dollars, conclu avec le Chief Digital and Artificial Intelligence Office (CDAO), s'inscrit dans l'initiative "OpenAI for Government" ActuIA, qui vise à fournir des solutions d'IA aux institutions publiques américaines.

Ce qui a déclenché l'affaire

Le Pentagone avait imposé à Anthropic (l'entreprise derrière Claude) un ultimatum : abandonner ses restrictions interdisant l'usage de son IA pour la surveillance de masse ou les armes autonomes, ou perdre son contrat. NPR Anthropic a refusé. L'administration Trump a alors ordonné à toutes les agences fédérales de cesser toute collaboration avec Anthropic, désignant l'entreprise comme "risque pour la chaîne d'approvisionnement" Génération NT — une catégorie normalement réservée aux entités étrangères hostiles. OpenAI a saisi l'opportunité et signé son propre accord dans les heures qui ont suivi.

Les garde-fous annoncés… et contestés

OpenAI affirme que ses modèles ne peuvent pas être utilisés pour la surveillance de masse domestique, les systèmes d'armes autonomes, ni les décisions automatisées à enjeux élevés (type "crédit social"). TechCrunch Cependant, Sam Altman lui-même a reconnu que le contrat initial était "opportuniste et bâclé" et que les négociations avaient été précipitées. Clubic Face aux critiques, le texte a été amendé pour clarifier ces restrictions.

Les enjeux pour la cybersécurité

Le déploiement prévu inclut l'accès à ChatGPT Enterprise et ChatGPT Government dans des environnements isolés, ainsi que le développement de modèles sur mesure pour la sécurité nationale. ActuIA OpenAI vise également un contrat pour un déploiement sur les réseaux classifiés de l'OTAN, ce qui ouvrirait les portes de 31 États membres. Moyens I/O

Réactions de l'industrie

Plus de 700 employés d'OpenAI et de Google ont signé une lettre ouverte pour dénoncer les risques liés à cet accord, notamment la surveillance de masse et la possibilité de "tuer de manière autonome sans supervision humaine". Contre Attaque La controverse a été telle que Claude d'Anthropic a dépassé ChatGPT dans l'App Store américain le week-end suivant l'annonce. TechCrunch

Analyse personnelle

Cet événement illustre une tension fondamentale dans le secteur de l'IA : jusqu'où les entreprises privées peuvent-elles collaborer avec les gouvernements sans compromettre leurs principes éthiques ? Du point de vue SISR, cela soulève des questions concrètes sur la gouvernance des IA déployées dans des infrastructures critiques, la responsabilité humaine dans la prise de décision automatisée, et les risques liés à l'intégration de modèles de langage dans des environnements classifiés. La frontière entre outil d'aide à la décision et système autonome reste floue — et c'est précisément ce flou qui inquiète la communauté cybersécurité.

Sources : NPR · TechCrunch · Clubic · generation-nt.com · actuia.com — Mars 2026